

- 1 Introduction
- 2 Étape 1 : Données d'occurrence (GBIF + Coordonnées spatiales)
- 3 Étape 2 : Nettoyage des occurrences
- 4 Étape 3 : Shapefile de la zone d'étude (GADM)
- 5 Étape 4 : Données NDVI MODIS
- 6 Étape 5 : Données climatiques
- 7 Étape 6 : Analyse du verdissement (Greenup)
- 8 Étape 7 : Génération des pseudo-absences
- 9 Étape 8 : Préparation des prédicteurs
- 10 Étape 9 : Modèle Random Forest
- 11 Étape 10 : Évaluation du modèle
- 12 Étape 11 : Carte de risque d'invasion
- 13 Étape 12 : Résumé des régions à risque
- 14 Étape 13 : Rapport complet (HTML + PDF)
- 15 Étape 14 : Bulletin mensuel d'alerte
- 16 Jeu de données exemple
- 17 Résumé des fonctions
- 18 Sources des données
- 19 Références

locustTrack : Prédiction du Risque d'Invasion du Criquet Pèlerin

Salma Oubrayme

2026-06-09

1 Introduction

Le **criquet pèlerin** (*Schistocerca gregaria*) est l'un des ravageurs agricoles les plus dévastateurs au monde. Il menace la sécurité alimentaire de plus de 65 pays en Afrique, au Moyen-Orient et en Asie du Sud-Ouest.

Le package `locustTrack` fournit un ensemble de fonctions R pour :

- **Importer** les données d'occurrence depuis GBIF, FAO ou iNaturalist
- **Télécharger** les données environnementales (NDVI MODIS, WorldClim)
- **Modéliser** le risque d'invasion via Random Forest
- **Cartographier** les zones à risque
- **Générer** des bulletins d'alerte HTML/PDF

1.1 Workflow général

```
GBIF/FAO (occurrences) + Shapefile GADM (zone d'étude)
↓
clean_occurrences()
↓
download_ndvi() + download_climate_data()
↓
generate_background_points()
↓
prepare_predictors()
↓
train_rf_model()
↓
evaluate_model() + predict_risk_map()
↓
generate_report() + generate_alert_bulletin()
```

1.2 Installation

```
# Depuis GitHub
remotes::install_github("oubrayme20/locustTrack")

# Charger Le package
library(locustTrack)
```

2 Étape 1 : Données d'occurrence (GBIF + Coordonnées spatiales)

La première étape consiste à importer les **données de présence** du criquet pèlerin. Ces données fournissent les **coordonnées géographiques réelles** (latitude/longitude) des observations – c'est la base spatiale de toute l'analyse.

```

library(locustTrack)

# Télécharger Les occurrences depuis GBIF
# hasCoordinate = TRUE garantit que chaque observation a des coords GPS
df_raw <- import_locust_data(
  source = "gbif",
  limit = 500
)

# Aperçu des données
head(df_raw)
#>   Latitude Longitude      date presence
#> 1    15.23    38.45 2021-03-12         1
#> 2    12.67    42.18 2021-04-05         1
#> 3    11.89    43.52 2020-11-23         1

cat("Nombre d'occurrences GBIF :", nrow(df_raw), "\n")
cat("Étendue spatiale :\n")
cat("  Latitudes  :", range(df_raw$latitude, na.rm = TRUE), "\n")
cat("  Longitudes :", range(df_raw$longitude, na.rm = TRUE), "\n")

```

Lien GBIF → Shapefile : Les coordonnées GBIF définissent automatiquement la zone d'étude. Le NDVI sera ensuite extrait exactement sur cette zone.

3 Étape 2 : Nettoyage des occurrences

```

# Nettoyer : supprimer coords invalides, doublons, outliers
df_clean <- clean_occurrences(
  df_raw,
  lon_min = -20,
  lon_max = 65,
  lat_min = -10,
  lat_max = 40
)

cat("Occurrences conservées :", nrow(df_clean),
    "sur", nrow(df_raw), "\n")

```

4 Étape 3 : Shapefile de la zone d'étude (GADM)

Réponse à la remarque de la prof : Les coordonnées GBIF donnent les localisations des observations. Le shapefile GADM délimite précisément la zone géographique d'étude. Le NDVI est ensuite extrait et masqué sur cette zone — assurant que chaque pixel NDVI correspond à une zone terrestre réelle couvrant l'aire de distribution du criquet pèlerin.

```

library(terra)
library(geodata)

# Télécharger les shapefiles GADM des pays de la zone d'étude
# (Maghreb + Afrique subsaharienne + Moyen-Orient)
pays_etude <- c(
  "MAR", "DZA", "TUN", "LBY", "EGY",    # Maghreb + Égypte
  "MRT", "MLI", "NER", "SDN", "TCD",    # Sahel
  "ETH", "SOM", "DJI", "ERI",           # Corne de l'Afrique
  "SAU", "YEM", "OMN", "ARE", "IRN",    # Péninsule arabique + Iran
  "PAK", "IND"                          # Asie du Sud
)

# Télécharger le shapefile (level=0 = frontières nationales)
zone_shp <- geodata::gadm(
  country = pays_etude,
  level   = 0,
  path    = "data/shapefiles/"
)

# Convertir en objet terra (SpatVector)
zone_vect <- terra::vect(zone_shp)

# Visualiser la zone d'étude avec les occurrences
terra::plot(zone_vect,
  col = "#f0f0f0",
  main = "Zone d'étude – Criquet pèlerin")

# Superposer les points d'occurrence GBIF
points(df_clean$longitude, df_clean$latitude,
  pch = 20, col = "#e74c3c", cex = 0.8)

legend("bottomleft",
  legend = "Occurrences GBIF",
  pch     = 20,
  col     = "#e74c3c",
  cex     = 0.8)

```

5 Étape 4 : Données NDVI MODIS

Le NDVI (Normalized Difference Vegetation Index) mesure l'état de la végétation. Le criquet pèlerin se développe dans les zones où la végétation verduit après des pluies – c'est le signal clé à capturer.

```

# Télécharger Le NDVI MODIS
# occurrences = df_clean → bbox calculée depuis les coords GBIF réelles
ndvi <- download_ndvi(
  annee      = 2023,
  mois       = 6,          # Juin : saison favorable
  occurrences = df_clean   # ← Utilise les coordonnées GBIF pour la bbox
)

# Masquer Le NDVI avec le shapefile (terres uniquement)
ndvi_zone <- terra::mask(ndvi, zone_vect)

# Visualiser
terra::plot(ndvi_zone,
  main = "NDVI Juin 2023 – Zone criquet pèlerin",
  col  = grDevices::colorRampPalette(
    c("#d73027", "#fee08b", "#1a9850"))(100))

# Superposer les occurrences
points(df_clean$longitude, df_clean$latitude,
  pch = 20, col = "blue", cex = 0.6)

cat("NDVI moyen sur la zone :",
  round(mean(terra::values(ndvi_zone), na.rm = TRUE), 3), "\n")

```

5.1 Évolution temporelle du NDVI

```

# Analyser L'évolution sur toute L'année
temporal <- plot_temporal(
  annee      = 2023,
  mois_debut = 1,
  mois_fin   = 12,
  occurrences = df_clean, # bbox depuis coordonnées réelles
  export     = TRUE,
  dossier    = "outputs"
)

# Résumé
print(temporal[, c("nom_mois", "ndvi_moyen")])

```

6 Étape 5 : Données climatiques

```
# Précipitations WorldClim
clim_prec <- download_climate_data(
  var      = "prec",
  res      = 10,
  lon_min  = -20, lon_max = 65,
  lat_min  = -10, lat_max = 40
)

# Température moyenne
clim_temp <- download_climate_data(
  var      = "tavg",
  res      = 10,
  lon_min  = -20, lon_max = 65,
  lat_min  = -10, lat_max = 40
)

# Empiler précipitations + température
clim_stack <- c(clim_prec, clim_temp)

# Masquer avec le shapefile
clim_zone <- terra::mask(clim_stack, zone_vect)

cat("Couches climatiques :", terra::nlyr(clim_zone), "\n")
terra::plot(clim_zone[[1]],
            main = "Précipitations janvier – Zone d'étude")
```

7 Étape 6 : Analyse du verdissement (Greenup)

Le verdissement post-pluie est un indicateur clé du risque acridien : les criquets pondent dans les zones qui verdissent rapidement après les pluies.

```

# Comparer NDVI avant et après la saison des pluies
ndvi_jan <- download_ndvi(2023, mois = 1, occurrences = df_clean)
ndvi_jul <- download_ndvi(2023, mois = 7, occurrences = df_clean)

# Calculer l'anomalie de végétation
greenup <- calculate_greenup(
  ndvi_avant = ndvi_jan,
  ndvi_apres = ndvi_jul,
  seuil_greenup = 0.1
)

# Visualiser l'anomalie NDVI
terra::plot(greenup$anomalie,
  main = "Anomalie NDVI (Juillet - Janvier 2023)",
  col = grDevices::colorRampPalette(
    c("#d73027", "#ffffff", "#1a9850"))(100))

# Statistiques du greenup
print(greenup$stats)

```

8 Étape 7 : Génération des pseudo-absences

Le modèle Random Forest nécessite des données de **présence** (GBIF) et d'**absence** (points background). Les pseudo-absences sont générées aléatoirement dans la zone d'étude, hors des zones de présence.

```

# Générer Les points background (pseudo-absences)
dataset_complet <- generate_background_points(
  occurrences = df_clean,
  raster_ref = clim_zone[[1]], # Référence spatiale = raster climatique
  n_points = nrow(df_clean), # Ratio 1:1 présences/absences
  lon_min = -20, lon_max = 65,
  lat_min = -10, lat_max = 40,
  seed = 42
)

# Résumé
table(dataset_complet$presence)
#> absence presence
#>      342      342

```

9 Étape 8 : Préparation des prédicteurs

Cette étape extrait les valeurs environnementales (pluie, température, NDVI) aux coordonnées de chaque point (présence et absence).

```
# Préparer Le dataset pour Random Forest
dataset <- prepare_predictors(
  occurrences = dataset_complet,
  climat      = clim_zone,
  ndvi        = ndvi_zone,
  greenup     = greenup$anomalie, # Anomalie végétation
  seuil_cor   = 0.9               # Supprimer variables très corrélées
)

cat("Dataset final :", nrow(dataset), "observations x",
    ncol(dataset), "variables\n")
head(dataset[, 1:6])
```

10 Étape 9 : Modèle Random Forest

```
# Entraîner Le modèle Random Forest
# Split 70% train / 30% test, seed = 42 pour reproductibilité
rf <- train_rf_model(
  dataset      = dataset,
  prop_train   = 0.7,
  ntree        = 500,
  seed         = 42
)

# Importance des variables
print(rf$importance[1:5, ])
#>      variable MeanDecreaseGini
#> clim_06   clim_06           45.231  ← précipitations juin
#> ndvi       ndvi            38.892  ← végétation
#> clim_07   clim_07           32.115  ← précipitations juillet
#> greenup   greenup           28.447  ← anomalie végétation
#> clim_01   clim_01           21.334
```

11 Étape 10 : Évaluation du modèle

```

# Calculer Les métriques de performance sur le jeu de test
eval <- evaluate_model(
  rf_result = rf,
  export    = TRUE,
  dossier   = "outputs"
)

# Résultats
print(eval$metriques)
#>               Metrique Valeur
#> 1               Accuracy 0.8721
#> 2 Sensibilite (Recall) 0.8534
#> 3               Specificite 0.8908
#> 4               Precision 0.8812
#> 5               F1-Score 0.8671
#> 6               AUC 0.9234

# Matrice de confusion
print(eval$matrice_confusion)

```

Interprétation : Un AUC > 0.90 indique un modèle **excellent**. La sensibilité élevée signifie que le modèle détecte correctement la plupart des zones de présence réelle du criquet.

12 Étape 11 : Carte de risque d'invasion

```

# Prédire Le risque sur tout Le territoire
risk <- predict_risk_map(
  rf_result = rf,
  climat     = clim_zone,
  ndvi       = ndvi_zone,
  greenup    = greenup$anomalie,
  seuil_moyen = 0.3,    # Risque moyen si prob > 0.3
  seuil_eleve = 0.6     # Risque élevé si prob > 0.6
)

# Résumé des zones à risque
print(risk$stats)
#>      Niveau N_pixels Pct
#> 1 Faible(1)    8432 61.2
#> 2 Moyen(2)    3521 25.6
#> 3 Eleve(3)    1834 13.2

```

12.1 Visualisation des cartes

```
# Générer et exporter toutes Les cartes
plot_risk_map(
  risk_result      = risk,
  ndvi             = ndvi_zone,
  greenup_result  = greenup,
  occurrences      = df_clean,
  export           = TRUE,
  format           = "png",
  dossier          = "outputs"
)
```

13 Étape 12 : Résumé des régions à risque

```
# Statistiques par région géographique
summary_risk <- summarize_risk_regions(
  risk_result      = risk,
  seuil_hotspot    = 0.7  # Hotspot si prob > 0.7
)

# Résumé par niveau de risque avec surfaces en km²
print(summary_risk$resume)
#>   Niveau N_pixels Surface_km2 Pourcentage Prob_moyenne
#> 1 Faible      8432      843200         61.2         0.142
#> 2 Moyen       3521      352100         25.6         0.453
#> 3 Eleve       1834      183400         13.2         0.734

# Statistiques par région
print(summary_risk$stats_pays)
```

14 Étape 13 : Rapport complet (HTML + PDF)

```
# Générer Le rapport complet
rapport <- generate_report(
  occurrences      = df_clean,
  rf_result        = rf,
  eval_result      = eval,
  risk_result      = risk,
  summary_result   = summary_risk,
  greenup_result   = greenup,
  annee            = 2023,
  dossier          = "outputs"
)

# Le rapport est disponible en HTML et PDF
cat("Rapport HTML :", rapport$html, "\n")
cat("Rapport PDF  :", rapport$pdf,  "\n")
```

15 Étape 14 : Bulletin mensuel d'alerte

```
# Générer un bulletin d'alerte pour juin 2023
bulletin <- generate_alert_bulletin(
  risk_result      = risk,
  summary_result   = summary_risk,
  greenup_result   = greenup,
  mois             = 6,
  annee            = 2023,
  dossier          = "outputs"
)

cat("Bulletin :", bulletin$html, "\n")
```

16 Jeu de données exemple

Le package inclut un jeu de données d'occurrences réelles prêt à l'emploi :

```
# Charger Le jeu de données intégré
data("locust_sample")

# Aperçu
head(locust_sample)
#>   Latitude Longitude    date presence
#> 1    15.23     38.45 2021-03-12        1
#> 2    12.67     42.18 2021-04-05        1

# Utilisation directe (sans téléchargement GBIF)
df_exemple <- clean_occurrences(locust_sample)
cat("Occurrences exemple :", nrow(df_exemple), "\n")
```

17 Résumé des fonctions

Fonction	Rôle
<code>import_locust_data()</code>	Importer occurrences (GBIF, FAO, iNaturalist, CSV)
<code>clean_occurrences()</code>	Nettoyer les données spatiales
<code>download_ndvi()</code>	Télécharger NDVI MODIS
<code>download_climate_data()</code>	Télécharger données WorldClim/CHIRPS
<code>calculate_greenup()</code>	Analyser le verdissement post-pluie
<code>generate_background_points()</code>	Générer les pseudo-absences
<code>prepare_predictors()</code>	Extraire les variables aux points
<code>train_rf_model()</code>	Entraîner Random Forest
<code>evaluate_model()</code>	Évaluer les performances
<code>predict_risk_map()</code>	Prédire la carte de risque
<code>plot_risk_map()</code>	Visualiser les cartes
<code>summarize_risk_regions()</code>	Résumé par région + km ²
<code>generate_report()</code>	Rapport complet HTML/PDF
<code>generate_alert_bulletin()</code>	Bulletin mensuel HTML/PDF

18 Sources des données

Source	Type	URL
GBIF	Occurrences biologiques	gbif.org/species/1711088 (https://www.gbif.org/species/1711088)
FAO Locust Hub	Données officielles FAO	locust-hub-hqfao.hub.arcgis.com (https://locust-hub-hqfao.hub.arcgis.com)
MODIS MOD13Q1	NDVI satellitaire	ORNL DAAC (https://modis.ornl.gov)
WorldClim	Données climatiques	worldclim.org (https://www.worldclim.org)
CHIRPS	Précipitations haute résolution	chc.ucsb.edu (https://www.chc.ucsb.edu/data/chirps)
GADM	Shapefiles administratifs	gadm.org (https://gadm.org)

19 Références

- GBIF.org (2023). *Schistocerca gregaria* occurrence data. <https://www.gbif.org/species/1711088> (<https://www.gbif.org/species/1711088>)
- FAO (2023). *Desert Locust Information Service*. <http://www.fao.org/ag/locusts/> (<http://www.fao.org/ag/locusts/>)
- Didan, K. (2015). MOD13Q1 MODIS/Terra Vegetation Indices 16-Day L3 Global 250m SIN Grid V006. NASA EOSDIS Land Processes DAAC.
- Fick, S.E. & Hijmans, R.J. (2017). WorldClim 2: new 1-km spatial resolution climate surfaces for global land areas. *International Journal of Climatology*, 37(12), 4302–4315.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45, 5–32.